PREPARACIÓN DEFENSA ORAL · 21 MAYO 2026

FAQs — Preguntas frecuentes del tribunal

Aguacate Team · TFM "La Dieta de un País" · Nuclio Digital School · Actualizado 03/04/2026

¿Para qué sirve este documento?

Las preguntas que surgen al leer la documentación del proyecto son exactamente las que hará el tribunal en la defensa oral. Este documento recoge esas preguntas y sus respuestas completas, organizadas por categoría. Se actualiza a lo largo del proyecto conforme van surgiendo nuevas dudas.

DATOS Y FUENTES

Q1 ¿Por qué habéis elegido estos tres datasets y no otros? Datos

Los tres datasets responden directamente a los tres ejes del proyecto: **qué come un país** (FBS), **cuánto le cuesta** (CPI) y **cuánto contamina** (Emissions). Cada eje necesitaba un dato y elegimos el dataset que mejor lo cubría.

La decisión central fue usar los **tres datasets de la misma fuente** (FAOSTAT/FAO). Eso no es casualidad — es una decisión metodológica deliberada. Al venir de la misma institución con la misma metodología de recolección, los problemas de integración se minimizan: mismos nombres de países, mismos períodos, unidades coherentes.

Para el eje nutricional, el FBS es **el único dataset que existe** con esa cobertura global. No hay alternativa pública comparable. Las encuestas de consumo individual (como ENSE en España) solo cubren un país. Los datos privados (Nielsen, Euromonitor) no cubren países en desarrollo y son de pago.

Para el coste descartamos el FFPI (FAO Food Price Index) porque es un índice **global**, no por país. No nos sirve para comparar España con India. El Food CPI sí es por país.

> **Respuesta corta para el tribunal:** Los tres datasets cubren los tres ejes del proyecto, son de la misma fuente (coherencia metodológica), tienen cobertura global comparable, son públicos y gratuitos, y no existe una alternativa superior accesible para los tres a la vez.

Q2 ¿Por qué Viet Nam y no Japón? Japón tiene una dieta muy diferenciada. Datos

Japón era nuestra primera opción por exactamente esa razón: su dieta es única. El problema es que **Japón no reporta sus datos a la FAO usando la metodología Food Balance Sheets**. Tiene su propio sistema estadístico nacional y simplemente no existe en el dataset FBS con ninguna variante del nombre.

No es un error técnico. Es una decisión soberana de Japón de no integrarse en el sistema estadístico de la FAO para este dominio. Sus datos de emisiones y CPI sí existen en FAOSTAT, pero sin el FBS no podemos hacer el análisis nutricional.

Viet Nam cumple todos los criterios de sustitución:

- Cobertura completa en los tres datasets (FBS, Emissions, CPI)
- Perfil dietario diferenciado: alta dependencia del arroz y la acuicultura
- Suficiente contraste respecto a Indonesia y Tailandia, que ya están en la lista
- Representa el modelo de transición económica y dietaria del sudeste asiático

> **Respuesta corta para el tribunal:** Japón no está en el FBS de la FAO — es una limitación de datos, no una elección. Viet Nam es el sustituto más robusto por cobertura completa y perfil dietario diferenciado.

Q4 ¿Por qué usáis el CPI como "proxy" del coste? ¿No podríais medir el coste directamente? Datos Limitación

Un **proxy** es una variable que no mide exactamente lo que queremos, pero se aproxima suficientemente bien para ser útil en el análisis.

Lo que querríamos medir idealmente es cuánto gasta realmente una familia en alimentarse en cada país. Ese dato **no existe de forma comparable, pública y global**. Las encuestas de gasto del hogar existen por país, pero con metodologías distintas, periodicidades distintas y niveles de detalle incomparables entre naciones.

Lo que usamos en su lugar es el Food CPI, que no mide el gasto absoluto sino **cómo han evolucionado los precios** respecto al año base 2015. No te dice que en India la comida cuesta 0.80€ por kcal — te dice que en India la comida es un 40% más cara que en 2015.

El CPI tiene dos limitaciones concretas que hay que documentar:

- **Es relativo, no absoluto.** Un CPI de 120 en Nigeria y 120 en Alemania no significa que la comida cueste igual — solo que ambos subieron un 20% desde 2015. Los niveles de partida son completamente distintos.
- **No captura el coste real de la dieta**, sino la inflación alimentaria general del país. No distingue si suben los cereales o la carne.

¿Cómo usamos la señal del CPI concretamente? No comparamos el valor absoluto entre países — eso no es válido. Lo usamos de tres formas distintas:

- **Como feature del modelo supervisado.** El CPI anual de cada país-año entra como una variable más en LightGBM junto al vector de macrocategorías. El modelo aprende si hay una relación entre "países con dietas más carnívoras" y "países con mayor inflación alimentaria". No afirmamos que la carne cause inflación — el modelo detecta si esa correlación existe en los datos.
- **Como variable de contexto temporal.** Para un mismo país, comparamos su CPI a lo largo de los 13 años. Si España pasa de CPI 100 en 2015 a 132 en 2022, eso indica que su dieta se ha encarecido un 32%. Podemos cruzar eso con si su composición dietaria cambió en el mismo período: ¿subió el consumo de proteína animal justo cuando subió el CPI?

- **Como output del simulador What-If.** Cuando el usuario simula "España reduce carne -10%", el simulador no solo predice el cambio en CO2 — también estima el cambio en CPI esperado, porque los países con ese perfil dietario tienden a tener un CPI más bajo o más estable.

La regla de comparación que aplicamos: no comparamos CPI entre países distintos (inválido). Sí comparamos el mismo país consigo mismo en el tiempo, y la tendencia del CPI de países agrupados en el mismo cluster dietario. Si el cluster de "dietas con alta proteína animal" muestra sistemáticamente mayor crecimiento del CPI entre 2015 y 2022 que el cluster de "dietas con base vegetal", esa es una señal robusta — aunque no sepamos si la comida es más cara en términos absolutos.

> **Respuesta corta para el tribunal:** El coste real de la dieta por país no existe como dato público y comparable a nivel global. El Food CPI es el mejor proxy disponible. Lo usamos de tres formas: como feature del modelo, como contexto temporal por país, y como output del simulador What-If. Nunca comparamos niveles absolutos entre países — solo tendencias y patrones por cluster.

Q5 ¿Qué es el CPI exactamente y cómo se interpreta? Datos

El **CPI (Consumer Price Index / Índice de Precios al Consumidor)** es un número que mide cuánto han subido o bajado los precios de un conjunto de bienes a lo largo del tiempo. No mide precios absolutos — mide **variación relativa respecto a un año de referencia**.

Se elige un año base al que se le asigna el valor 100. A partir de ahí, si los precios suben el índice sube por encima de 100; si bajan, cae por debajo. En nuestro caso el año base es **2015 = 100**.

Ejemplo concreto con el Food CPI:

- **España: CPI 2022 = 132** → la comida es un 32% más cara que en 2015
- **Nigeria: CPI 2022 = 198** → la comida casi se ha duplicado de precio
- **Japón: CPI 2022 = 104** → precios prácticamente estables

Estos tres países con CPI muy distintos no permiten concluir que Nigeria es más cara que España en términos absolutos — solo que **Nigeria ha experimentado una inflación alimentaria mucho más severa desde 2015**. Los niveles de partida son completamente distintos.

Usamos el **Food CPI** específicamente (no el CPI general) porque aísla solo la componente alimentaria, excluyendo vivienda, transporte, energía y otros bienes. Para un proyecto sobre dietas, esa es exactamente la señal que necesitamos.

> **Respuesta corta para el tribunal:** El Food CPI mide la variación relativa del precio de los alimentos en cada país usando 2015 como base (=100). Un valor de 150 significa que los alimentos son un 50% más caros que en 2015 en ese país. No permite comparar niveles de precios absolutos entre países — solo tendencias.

Q3 ¿Qué es el Simulador What-If y cuál es su utilidad práctica? Negocio Metodología

El simulador What-If es una calculadora de consecuencias dietarias en tiempo real.

La idea central en una frase: *"Si un país cambia lo que come, ¿cuánto CO2 se ahorra y cuánto más o menos le cuesta?"*

Cómo funciona por dentro: el modelo LightGBM aprende la relación entre la composición de la dieta y las emisiones CO2eq/cápita. Una vez entrenado, puede recibir cualquier vector dietario hipotético — no solo los reales — y predecir las emisiones que le corresponderían. El simulador es básicamente un formulario encima del modelo:

- El usuario elige un país (por ejemplo, España)
- Ve su dieta actual en porcentajes: 30% cereales, 22% carnes, 15% lácteos...
- Mueve sliders: "bajo carnes -10%, subo frutas y verduras +7%, subo legumbres +3%"
- El modelo calcula al instante: **-0.8 t CO2eq/persona/año** y **-4% en índice CPI estimado**
- Bonus: "Este perfil modificado se parece al de Tailandia en 2018"

Por qué es la pieza central de la defensa — tres razones:

- **Convierte ciencia en decisión.** Un tribunal de negocio no recuerda un R^2 de 0.63. Sí recuerda: "si España reduce la carne un 10%, evita el equivalente a 4 millones de toneladas de CO2 al año".
- **Es interactivo durante la exposición.** En los 20 minutos de defensa se puede abrir el dashboard en vivo y hacer la simulación delante del tribunal. No es una diapositiva estática — es una demostración. Eso es diferenciador.
- **Responde la pregunta de negocio real.** Las políticas alimentarias (etiquetado nutricional, impuestos al azúcar, subvenciones a legumbres) necesitan exactamente esta herramienta: cuantificar el trade-off entre coste y sostenibilidad antes de legislar.

> **Limitación importante a comunicar:** El modelo predice CO2eq a nivel sistema completo del país, no por alimento individual. Lo que calcula no es "la carne de vacuno emite X g CO2 por kcal" — eso requeriría datos de ciclo de vida por producto. Calcula: "países con esta estructura dietaria tienden a tener estas emisiones sistémicas". Es una correlación robusta, no causalidad directa por alimento. Decirlo explícitamente en la defensa es un punto a favor — demuestra rigor metodológico.

Q6 ¿Por qué LightGBM y no otro modelo supervisado? Metodología Negocio

LightGBM (Light Gradient Boosting Machine) es un algoritmo de aprendizaje automático desarrollado por Microsoft en 2017. Pertenece a la familia de los *gradient boosting* — modelos que construyen muchos árboles de decisión simples de forma secuencial, donde cada árbol corrige los errores del anterior. El resultado final es la suma ponderada de todos ellos.

Cómo se diferencia de sus competidores:

- **Frente a Regresión Lineal:** la regresión lineal asume que la relación entre variables es una línea recta. En la realidad, el impacto de "más carne en la dieta" sobre las emisiones no es lineal — tiene umbrales, interacciones con otros grupos alimentarios, diferencias por región. LightGBM captura esas relaciones no lineales sin que tengamos que especificarlas manualmente.
- **Frente a Random Forest:** ambos usan árboles de decisión, pero Random Forest los construye en paralelo de forma independiente. LightGBM los construye de forma secuencial y aprende de los errores — esto lo hace más preciso con el mismo número de árboles, y mucho más rápido en datasets grandes.
- **Frente a XGBoost** (su competidor más directo): LightGBM usa una técnica llamada *leaf-wise growth* (crece por la hoja con mayor ganancia) en lugar de *level-wise* (crece nivel a nivel). Resultado: converge más rápido, consume menos memoria y en la mayoría de benchmarks obtiene igual o mejor precisión. En datasets con muchas filas como el nuestro, la diferencia de velocidad es significativa.
- **Frente a Redes Neuronales:** para tabular estructurado (filas y columnas, como nuestros datos) LightGBM iguala o supera a las redes neuronales en precisión con una fracción del coste computacional y sin necesidad de GPU. Las redes neuronales brillan en imágenes, texto y audio — no en tablas.

Por qué encaja específicamente en este proyecto:

- Nuestro dataset final tendrá ~390 filas (30 países × 13 años). Es un dataset pequeño. LightGBM funciona bien con muestras pequeñas; las redes neuronales necesitan miles de ejemplos.
- Maneja bien los **valores faltantes** de forma nativa — no hay que imputarlos antes de entrenar.
- Es completamente compatible con **SHAP**, la herramienta que usamos para explicar qué variables impulsan cada predicción. Sin interpretabilidad, el modelo no sirve para la defensa.
- Entrenamiento en **segundos** en CPU estándar — podemos iterar rápido y probar múltiples configuraciones sin infraestructura especial.

Una nota personal que refuerza la elección: LightGBM ha sido el modelo empleado en 3 proyectos distintos a lo largo del máster, en dominios completamente diferentes, obteniendo resultados sólidos en todos ellos. Esa consistencia no es casualidad — es la característica definitoria del algoritmo: funciona bien casi por defecto, sin necesidad de un ajuste exhaustivo de hiperparámetros, y rara vez decepciona en datos tabulares del mundo real.

> **Respuesta corta para el tribunal:** LightGBM captura relaciones no lineales que la regresión lineal no puede, es más rápido y eficiente que XGBoost y Random Forest, funciona bien con datasets pequeños como el nuestro, maneja nulos de forma nativa y es totalmente interpretable con SHAP. Es el estándar de facto en competiciones de datos tabulares y en proyectos de DS aplicado por una razón: funciona.

Q7 ¿Cómo funciona el pipeline de normalización de la dieta? ¿Qué entra, qué se transforma y qué sale? Metodología Datos

Sí, esto es un proceso **ETL** — *Extract, Transform, Load* — el estándar de ingeniería de datos para mover y transformar datos de una fuente a un destino procesado:

- **Extract:** leer el CSV bruto de FAOSTAT
- **Transform:** filtrar, mapear y normalizar

- **Load:** guardar el resultado en Parquet listo para modelizar

📩 ANTES — fbs_raw.csv (604 MB)

Dimensiones brutas
~174 millones de filas
120 ítems (alimentos)
→ 33 son *agregados* (ruido)
→ 87 son *hoja* (reales)
Múltiples elementos por ítem
Todos los países del mundo
Años: 1961 – 2023

Estructura de cada fila
Area → "Spain"
Year → 2018
Item → "Bovine Meat"
Element → "Food supply (kcal/capita/day)"
Value → 187.4

→ Una fila = un país, un año, un alimento, un elemento

▼

⚙️ EXTRACT — ¿Qué buscamos en el dataset?

✅ Lo que CONSERVAMOS

Elemento: `Food supply (kcal/capita/day)`

Ítems hoja (87 alimentos reales)
Años: 2010 – 2022
Los 30 países seleccionados
Columnas: Area, Year, Item, Value

❌ Lo que DESCARTAMOS

Otros elementos: proteína, grasa, producción, importaciones...

33 ítems agregados (Grand Total, Vegetal Products, Animal Products...)

Años < 2010 y > 2022
Países fuera de los 30 seleccionados

¿Por qué solo kcal? Porque es la unidad común que permite comparar alimentos tan distintos como el arroz y la carne en la misma escala. Proteínas y grasas se analizarían en unidades incomparables directamente entre sí.

▼

⚙️ TRANSFORM — Las 3 transformaciones

T1 — Mapeo 87 ítems → 7 macrocategorías
Cada alimento recibe una etiqueta de grupo mediante un diccionario:

`"Bovine Meat"` → `Carnes` `"Wheat and products"` → `Cereales`

`"Palm Oil"` → `Aceites_Grasas` `"Potatoes"` → `Tuberculos`

Los ítems sin categoría asignada se descartan (⚠️ tarea pendiente: completar el mapeo).

T2 — Agrupación y pivote
Se suman las kcal de todos los alimentos dentro de cada macrocategoría por país y año.
Luego se pivota: cada macrocategoría se convierte en una columna.

Antes del pivote:

```
Spain | 2018 | Cereales | 820 kcal
Spain | 2018 | Carnes | 612 kcal
Spain | 2018 | Aceites_Grasas | 480 kcal
...
```

Después del pivote:

```
Spain | 2018 | Cereales:820 | Carnes:612 | Aceites:480 | ...
```

T3 — Normalización a porcentajes (el núcleo)
Se calcula el total de kcal del país (`Total_DES_Kcal`) y cada macrocategoría se divide entre ese total:

```
%_Cereales = 820 / 3.240 = 25.3%
%_Carnes = 612 / 3.240 = 18.9%
%_Aceites = 480 / 3.240 = 14.8%
... (las 7 columnas suman siempre 100%)
```

¿Por qué porcentajes y no kcal absolutas? Porque queremos comparar la *estructura* de la dieta, no su tamaño. España con 3.200 kcal/día e India con 2.100 kcal/día pueden tener la misma proporción de cereales — eso las hace similares en patrón dietario aunque coman cantidades distintas.

▼

LOAD — diet_vector.parquet

Dimensiones resultantes

~390 filas (30 países × 13 años)
9 columnas:
- Area, Year
- %_Cereales
- %_Carnes
- %_Lacteos_Huevos
- %_Aceites_Grasas
- %_Azucares
- %_Frutas_Verduras
- %_Tuberculos
- Total_DES_Kcal

Ejemplo de fila resultante

Area: **Spain**
Year: **2018**
%_Cereales: **25.3%**
%_Carnes: **18.9%**
%_Lacteos_Huevos: **12.1%**
%_Aceites_Grasas: **14.8%**
%_Azucares: **9.4%**
%_Frutas_Verduras: **16.2%**
%_Tuberculos: **3.3%**
Total_DES_Kcal: **3.240**

Este parquet es el input directo del clustering K-Means. Cada fila es un "vector dietario" — la huella dactilar nutricional de un país en un año concreto.

▼

RESUMEN — ¿Qué descartamos y por qué?

Qué descartamos	Por qué
Elementos ≠ kcal *proteína, grasa, producción, importaciones...*	Solo nos interesa la energía disponible para consumo humano. Los demás elementos responden a otras preguntas (comercio, nutrición proteica...) que están fuera del alcance de este análisis.
33 ítems agregados *Grand Total, Vegetal Products, Animal Products...*	Son sumas de otros ítems — incluirlos produciría doble conteo. Irlanda aparecía con 15.000 kcal/día antes de este filtro.
Años < 2010	El FBS usa una metodología distinta antes de 2010. Mezclar ambas metodologías rompería la consistencia de las series temporales.
Años > 2022	Los datos de emisiones post-2022 son proyecciones, no mediciones reales. Para que el join con Emissions sea válido, acotamos todos los datasets al mismo período.
Países fuera de los 30	El análisis está diseñado sobre 30 países de máxima varianza. Incluir los 190+ países restantes añadiría ruido sin mejorar la calidad del clustering.

Respuesta corta para el tribunal: El pipeline de normalización es un proceso ETL clásico. Extrae del FBS únicamente las kcal por alimento individual (descartando agregados y otros elementos), mapea los 87

alimentos a 7 macrocategorías, normaliza a porcentajes para que los países sean comparables independientemente de su ingesta total, y guarda el resultado en Parquet. De 174 millones de filas y 604 MB entramos; ~390 filas y 9 columnas salen.

LOS 3 DATASETS EN DETALLE

Q8 ¿Por qué usamos las kcal como unidad de referencia y cómo se relaciona con los datos de cada dataset?

Datos · Metodología

Una **kilocaloría (kcal)** es la unidad de energía que el cuerpo extrae de los alimentos al metabolizarlos. Es lo que popularmente llamamos "caloría" en el contexto de la alimentación. Todo alimento — independientemente de si es arroz, carne, aceite o fruta — puede expresarse en kcal.

Los tres macronutrientes tienen densidades energéticas distintas y fijas:

4 kcal	4 kcal	9 kcal
por gramo	**por gramo**	**por gramo**
Hidratos de carbono	Proteínas	Grasas
(arroz, pan, azúcar, patata)	*(carne, pescado, huevos, legumbres)*	*(aceite, mantequilla, frutos secos)*

Esto significa que **las kcal son el denominador común** que permite comparar alimentos radicalmente distintos en la misma escala. Sin esta conversión, comparar "200g de arroz" con "80g de carne de vacuno" no tiene sentido directo — son magnitudes que miden cosas distintas. Convertidos a kcal: 200g de arroz ≈ 260 kcal, 80g de vacuno ≈ 190 kcal. Ahora sí son comparables.

¿Por qué no usar proteínas o grasas como unidad? Porque **no tienen escala común entre sí**. No puedes sumar gramos de proteína y gramos de grasa para obtener una magnitud significativa. Las kcal sí son sumables: la dieta total de un país es simplemente la suma de las kcal de todos sus alimentos.

La métrica concreta que usamos del FBS: `Food supply (kcal/capita/day)` — las kilocalorías disponibles para consumo humano por persona y día en cada país. No es lo que la gente come exactamente, sino lo que el sistema alimentario pone a disposición tras restar pérdidas, usos industriales y alimentación animal.

Los 3 datasets y sus variables clave

1 Food Balance Sheets (FBS) — 604 MB · Dataset principal

Columnas del CSV

- `Area` — nombre del país
- `Year` — año
- `Item` — alimento (120 posibles)
- `Element` — qué se mide

✅ Variables que extraemos

- `Food supply (kcal/capita/day)`
  → *base del vector dietario*
- `Total Population - Both sexes`
  → *para calcular CO2eq per cápita*

- `Value` — el número
- `Unit` — unidad (kcal, t, 1000 personas...)

❌ Variables que descartamos

- Producción, importaciones, exportaciones
- Uso como pienso, semilla, pérdidas
- Proteína (g/cápita/día), Grasa (g/cápita/día)

⚙️ **Trabajo de transformación necesario:** filtrar 33 agregados, mapear 87 ítems a 7 macrocategorías, normalizar a porcentajes, filtrar 30 países y período 2010–2022.

2 Emissions — Agrifood System — 347 MB · Eje climático

Columnas del CSV

- `Area` — país
- `Year` — año (1961–2050)
- `Item` — subsector (180+ posibles)
- `Element` — tipo de medición
- `Value` — emisiones en kt
- `Unit` — kilotoneladas (kt)

✅ Variables que extraemos

- `Item = "Agrifood systems"`
- `Element = "Emissions (CO2eq) (AR5)"`

  → *emisiones totales en kt CO2eq*

❌ Variables que descartamos

- Subsectores individuales (ganadería, cultivos, energía...)
- Otros gases por separado (CH4, N2O)
- Años > 2022 (proyecciones, no reales)

⚙️ **Trabajo de transformación necesario:** dividir Value (kt) entre la población de FBS para obtener CO2eq toneladas per cápita. Fórmula: `(CO2eq_kt × 1000) / (Population_1000 × 1000)`. Sin este paso el dato no es comparable entre países grandes y pequeños.

3 Consumer Price Indices (CPI) — 35.5 MB · Eje de coste

Columnas del CSV

- `Area` — país
- `Year` — año
- `Months` — mes (dato mensual)
- `Item` — categoría de precios
- `Element` — tipo de índice
- `Value` — índice (base 2015=100)

✅ Variables que extraemos

- `Item = "Consumer Prices, Food Indices (2015 = 100)"`

  → *inflación alimentaria por país*

❌ Variables que descartamos

- CPI general (no alimentario)
- Subcategorías de alimentos específicos
- Países sin cobertura en los 30 seleccionados

⚙️ **Trabajo de transformación necesario:** el CPI es mensual pero el FBS es anual. Calculamos la media de los 12 meses de cada año para obtener un CPI anual por país. Sin este paso no podemos hacer el join con los otros dos datasets.

Respuesta corta para el tribunal: Usamos kcal porque es la única unidad de energía alimentaria comparable entre todos los alimentos. De los tres datasets extraemos exactamente una variable clave de cada uno — kcal/cápita/día del FBS, CO2eq/cápita de Emissions y Food CPI del índice de precios — y los tres requieren

transformación antes de ser útiles: mapeo a macrocategorías, división por población y agregación mensual a anual respectivamente.

DECISIONES METODOLÓGICAS Y ANOMALÍAS DOCUMENTADAS

Q9 El Food CPI de un país tiene un valor de 1.076 (10x el precio de 2015). ¿Es un error? ¿Cómo lo tratáis? Datos Limitación Metodología

No es un error — es un dato **legítimo que refleja inflación alimentaria severa real**. Un CPI de 1.076 (base 2015=100) significa que los alimentos cuestan 10.76 veces más que en 2015 en ese país-año. Entre nuestros 30 países, los candidatos más probables son Etiopía o Nigeria, ambos con episodios documentados de inflación alimentaria extrema por conflictos, sequías y depreciación de moneda local.

Cómo afecta a cada fase del proyecto:

- **Clustering (notebook 03): sin impacto.** El clustering usa exclusivamente el vector de porcentajes dietarios — el CPI no entra como variable de agrupación.
- **Modelo LightGBM (notebook 04): impacto potencial.** Si el modelo aprende la relación CPI↔emisiones con este outlier sin tratar, puede crear una asociación sesgada basada en un caso extremo.
- **Simulador What-If: el más expuesto.** Las predicciones de cambio de coste dietario podrían distorsionarse si el modelo ha aprendido de una distribución no tratada.

Decisión metodológica adoptada — Opción B: Log Transform

En el notebook 04 (modelo supervisado), aplicaremos `log(Food_CPI)` antes de entrenar LightGBM. Esta es la solución estándar para variables económicas con distribución sesgada a la derecha. Comprime la escala sin eliminar información — el outlier sigue presente pero no domina el aprendizaje. Los resultados del simulador se reconvertirán a escala original con `exp()` para mostrar valores interpretables.

⏳ **Pendiente en notebook 04:** (1) Identificar el país-año exacto con CPI=1.076. (2) Aplicar `np.log(Food_CPI)` como transformación previa al entrenamiento. (3) Documentar en la memoria como decisión metodológica justificada. El dato se mantiene — no se imputa ni se elimina.

Respuesta corta para el tribunal: El CPI extremo es un dato real de inflación severa, no un error. Lo documentamos como outlier legítimo y aplicamos transformación logarítmica antes del modelado — práctica estándar en variables económicas con cola larga. El clustering no se ve afectado.

Q10 ¿Por qué el mismo ítem puede tener nombres distintos en FAOSTAT y cómo lo detectamos? Datos Limitación

FAOSTAT es una base de datos que agrupa múltiples dominios (FBS, Emissions, CPI, producción agrícola, comercio...) desarrollados en distintos momentos y por distintos equipos. Como resultado, **el mismo ítem físico puede aparecer con nombres ligeramente distintos según el dominio o la versión del CSV**.

El caso concreto que detectamos en Sesión 2:

- En la documentación FAO y otros dominios: `'Sunflower seed Oil'` (con espacio entre "seed" y "Oil")
- En el FBS normalizado real: `'Sunflowerseed Oil'` (sin espacio — una sola palabra)

Cuando aplicamos `df['Item'].map(MAPEO_FAO)`, Python busca coincidencia **exacta carácter a carácter**. Una diferencia de un espacio es suficiente para que el ítem no encuentre su categoría, quede como NaN y sea descartado silenciosamente. En este caso, 62 kcal/día de aceite de girasol desaparecían del vector dietario sin ningún aviso — el código no falla, simplemente pierde datos.

¿Cómo lo detectamos? Gracias al paso de validación de fugas que ejecuta el notebook antes de descartar los NaN:

- Calcula la media de kcal/día de cada ítem no mapeado
- Señala como 🔴 CRÍTICO cualquiera que supere 50 kcal/día
- `Sunflowerseed Oil` apareció con 62 kcal/día → detectado y corregido

La regla que aplicamos a partir de ahora: el nombre correcto es el que aparece en el CSV real, no el de la documentación. Antes de añadir un ítem al mapeo, verificar el nombre exacto con `df['Item'].unique()` sobre los datos reales.

> **Respuesta corta para el tribunal:** FAOSTAT usa nombres inconsistentes entre dominios para el mismo ítem. Lo mitigamos con un paso de validación que detecta ítems no mapeados con más de 50 kcal/día de contribución media — cualquier fuga significativa se alerta como crítica antes de descartar los datos.

DESPLIEGUE Y ACCESIBILIDAD

Q11 ¿Por qué no habéis desarrollado una app nativa para iOS y Android? ¿Cómo accede el tribunal desde el móvil durante la defensa?

Negocio · Metodología

La pregunta implica un trade-off habitual en producto digital: **app nativa vs. web accesible**. Aquí la respuesta es técnica, económica y estratégica a la vez.

¿Por qué no una app nativa?

- **Coste de distribución real:** publicar en Apple App Store requiere una cuenta de desarrollador de $99/año y un proceso de revisión de semanas. Google Play cuesta $25 de pago único pero también tiene revisión. Ambos implican compilación nativa (Swift/Kotlin o React Native/Flutter) — una capa técnica completamente ajena al stack de Data Science del proyecto.
- **El usuario objetivo no instala apps para una defensa de 20 minutos.** Pedir al tribunal que descargue una app en su teléfono antes de entrar en la sala introduce fricción innecesaria y un punto de fallo que no controlamos.

La solución adoptada: PWA sobre Streamlit Community Cloud

Una **PWA (Progressive Web App)** es una web app servida por HTTPS que el navegador permite "instalar" en la pantalla de inicio del teléfono sin pasar por ninguna tienda. El resultado visual es idéntico al de una app nativa:

icono en pantalla, apertura a pantalla completa, sin barra de URL.

Flujo exacto durante la defensa:

- Diapositiva 1 incluye una URL pública y un QR code
- Cada miembro del tribunal escanea el QR desde su cámara → la app se abre en el navegador
- Opcionalmente: "Añadir a pantalla de inicio" en iOS (Safari → Compartir) o Android (Chrome → Instalar app)
- Cada persona puede navegar su propio escenario de forma independiente — simultáneamente, sin interferir con la presentación en pantalla principal

Por qué es la decisión correcta para este contexto:

- **Coste cero.** Streamlit Community Cloud es gratuito. No hay infraestructura, no hay suscripciones, no hay tiempos de aprobación.
- **Deploy en horas, no semanas.** Se conecta el repositorio GitHub y la app queda publicada. Actualizaciones al instante sin proceso de revisión.
- **Disponible antes de que el tribunal llegue a la sala.** No depende de que nadie instale nada previamente.
- **El valor diferenciador no está en la plataforma, está en el modelo.** Un tribunal de Data Science evalúa la calidad del análisis, no si la interfaz es Flutter o Streamlit.

Ángulo de negocio — si esto fuera un producto real: La PWA es exactamente la estrategia que usan startups para validar producto antes de invertir en desarrollo nativo. "Mobile-first web" es un paso estándar en la secuencia: web → PWA → app nativa solo si los datos de uso lo justifican. En nuestro caso, el objetivo es demostrar viabilidad del modelo, no escalar a millones de usuarios — la PWA es el vehículo correcto para esa fase.

Respuesta corta para el tribunal: Una app nativa implicaría semanas de desarrollo ajeno al stack de DS y $99/año solo en licencias de Apple, para una demo de 20 minutos. La PWA sobre Streamlit Community Cloud logra el mismo objetivo — cada miembro del tribunal interactúa desde su móvil en tiempo real — con coste cero y deploy en horas. Es la decisión correcta para esta fase del proyecto.

Q12 ¿Qué puede hacer el usuario dentro de la aplicación? ¿Cuáles son sus funcionalidades?

Negocio Metodología

La aplicación está estructurada en **4 vistas funcionales independientes**, cada una con un objetivo concreto. El usuario puede navegar entre ellas libremente desde cualquier dispositivo.

1 Explorador de País — "¿Cómo come este país?"

- Seleccionar cualquiera de los 30 países del análisis
- Ver el perfil dietario actual: distribución porcentual por macrocategoría (Cereales, Carnes, Lácteos/Huevos, Aceites, Azúcares, Frutas/Verduras, Tubérculos)
- Ver la evolución temporal 2010–2022 de las tres variables clave: DES (kcal/cápita/día), Food CPI y CO2eq/cápita

- Identificar el cluster al que pertenece el país y qué otros países comparten ese perfil

2 Comparador — "¿En qué se diferencian dos países?"

- Seleccionar dos países y enfrentarlos lado a lado
- Contrastar su vector dietario, coste (CPI) e impacto climático (CO2eq) en el mismo gráfico
- Filtrar por año para ver si la diferencia entre países se amplía o reduce con el tiempo
- Ver si pertenecen al mismo cluster o a clusters distintos — y qué implica esa diferencia

3 Mapa de Clústeres — "¿Qué bloques dietarios existen en el mundo?"

- Ver los 30 países coloreados por cluster dietario sobre un mapa mundial
- Clicar un país en el mapa para ver su perfil resumido
- Filtrar por año y observar cómo algunos países cambian de cluster entre 2010 y 2022 — evidencia de transición dietaria
- Ver la descripción del cluster: nombre interpretativo, perfil promedio, países miembros y huella CO2eq media del grupo

4 Simulador What-If — "¿Qué pasa si este país cambia lo que come?"

- Elegir un país base como punto de partida
- Mover sliders por macrocategoría (+/- puntos porcentuales) con la restricción de que la suma se mantenga en 100%
- Ver al instante la predicción del modelo: variación estimada en CO2eq/cápita y en Food CPI
- Ver a qué país real se parece el escenario simulado: "tu perfil modificado se asemeja a Tailandia en 2019"

Por qué es la vista central de la defensa: cada miembro del tribunal puede introducir su propio escenario desde su móvil en tiempo real — "¿qué pasa si España reduce la carne un 20%?", "¿y si Brasil duplica los cereales?" — y obtener resultados distintos simultáneamente. Convierte la demo en una experiencia participativa, no una presentación pasiva.

Respuesta corta para el tribunal: La app tiene 4 vistas: Explorador de País (perfil y evolución temporal), Comparador (dos países enfrentados), Mapa de Clústeres (visión global de bloques dietarios) y Simulador What-If (predicción de CO2 y coste ante cambios dietarios hipotéticos). Las cuatro funcionan desde móvil sin instalación previa.

INGENIERÍA Y CALIDAD DE DATOS

Q14 ¿Qué fue el bug de pct_Lacteos_Huevos? ¿Cómo se detectó y qué lección deja para proyectos futuros?

Datos | Limitación | Metodología

Este fue un bug real ocurrido durante el desarrollo del proyecto. Lo documentamos aquí porque ilustra una clase de error muy común en proyectos de Data Science y porque el proceso de detección y corrección es en sí mismo un argumento técnico relevante.

¿Qué ocurrió exactamente?

❌ **Estado incorrecto (parquet original)**

```
pct_Lacteos_Huevos (media): 0.3%
pct_Lacteos_Huevos (mediana): 0.0%
España 2018: 0.48% (~12 kcal/día)
```

✅ **Estado correcto (parquet corregido)**

```
pct_Lacteos_Huevos (media): 14.9%
pct_Lacteos_Huevos (mediana): 16.8%
España 2018: 19.3% (~665 kcal/día)
```

¿Cuál fue la causa raíz?

El error tenía dos capas, una encima de la otra:

Capa 1 — Error de clasificación en ITEMS_AGREGADOS. En la Sesión 1 se identificó que el FBS contiene 33 ítems agregados (subtotales como `Grand Total`, `Animal Products`, `Vegetal Products`…) que producen doble conteo si se incluyen. Se construyó una lista `ITEMS_AGREGADOS` para excluirlos. En esa lista se incluyeron por error `'Eggs'` y `'Milk - Excluding Butter'`, tratándolos como si fueran agregados cuando en realidad son **ítems hoja** — las observaciones individuales de menor granularidad que no se pueden descomponer más. Filtrarlos eliminó la práctica totalidad de los lácteos y huevos del dataset.

El nombre `'Milk - Excluding Butter'` es especialmente engañoso: su sintaxis *"X - Excluding Y"* suena a que es un subtotal calculado ("toda la leche menos la mantequilla"), cuando en realidad es simplemente el nombre FAO para la leche fluida de consumo directo. Es un error de nomenclatura de la fuente, no nuestro — pero sí nuestra responsabilidad detectarlo.

Capa 2 — El fix se aplicó al código pero no al artefacto. En algún momento se detectó el error, se comentaron `Eggs` y `Milk` en `ITEMS_AGREGADOS`, pero el notebook `02_feature_engineering.ipynb` no se re-ejecutó. El parquet siguió siendo el del estado incorrecto. El código y el artefacto quedaron desincronizados.

¿Cómo se detectó?

No hubo ningún fallo explícito de código: el pipeline ejecutó sin errores, el parquet se generó, los porcentajes sumaban exactamente 1.0. El bug era silencioso.

Se detectó **por inspección estadística básica** al revisar la validez del parquet antes de arrancar el clustering:

- Se ejecutó `df[pct_cols].describe()` sobre el parquet
- `pct_Lacteos_Huevos` mostró media = 0.003, mediana = 0.000, percentil 75 = 0.004
- Con conocimiento de dominio básico (*"los lácteos y huevos representan ~10-15% de la dieta en la mayoría de países"*), ese 0.3% es un **outlier estadístico a nivel de categoría** — no un valor inusualmente alto o bajo de un país concreto, sino toda la categoría sistémicamente a cero
- La inspección de España 2018 confirmó: solo 12 kcal/día asignadas a Lacteos_Huevos (únicamente Cream), con Milk y Eggs ausentes

La señal de alarma fue esta: cuando una macrocategoría entera tiene mediana = 0 en un dataset de 30 países × 13 años, algo estructural está mal. No puede ser que más de la mitad del mundo no consuma ningún lácteo ni huevo.

¿Era evitable?

Parcialmente. La confusión con el nombre `'Milk - Excluding Butter'` es razonable — el formato FAO no ayuda. Lo que sí era evitable es que el error sobreviviera sin ser detectado:

- **El pipeline de validación de fugas miraba en la dirección equivocada.** Comprobaba que los ítems no mapeados no superasen 50 kcal/día (para detectar ítems que faltaban en el mapeo). Pero no comprobaba que los ítems conocidos y correctamente mapeados realmente llegasen al output. Un ítem excluido antes del mapeo es invisible para esa validación.
- **No había validación de rangos esperados sobre el output.** Si hubiese existido un test del tipo `assert df['pct_Lacteos_Huevos'].mean() > 0.05`, el error habría fallado en el momento en que se generó el parquet.
- **No se re-ejecutó el notebook tras modificar el fichero de dependencia.** Un cambio en `mapeo_fao_completo.py` invalida automáticamente cualquier artefacto generado a partir de él. Sin una política explícita de re-ejecución (o un sistema de tracking de dependencias), el desacoplamiento código/artefacto es inevitable.

¿Qué hacer en proyectos futuros para protegerse de esto?

1. Validación de rangos sobre el output

Definir rangos esperados para cada macrocategoría basados en conocimiento de dominio. Ejecutarlos como assertions al final del pipeline. Si fallan, el notebook debe detenerse y alertar — no continuar silenciosamente.

```
assert df['pct_Lacteos_Huevos'].mean() > 0.05
assert df['pct_Cereales'].mean() > 0.20
assert df['Total_DES_Kcal'].between(1500, 4500).all()
```

2. Test de ítems críticos en ITEMS_AGREGADOS

Antes de filtrar agregados, verificar explícitamente que los ítems hoja clave no están en esa lista. Una función de validación cruzada entre MAPEO_FAO e ITEMS_AGREGADOS detectaría cualquier solapamiento.

```
# Ningún ítem mapeado debe estar en agregados
overlap = set(MAPEO_FAO) & ITEMS_AGREGADOS
assert len(overlap) == 0, f"Conflicto: {overlap}"
```

3. Política de re-ejecución tras cambios

Cualquier cambio en un fichero de configuración o mapeo (`.py`) debe disparar la re-ejecución de todos los notebooks que lo importan. En proyectos pequeños: documentarlo como regla de equipo. En proyectos más grandes: usar DVC, Makefile, o papermill con checksums de inputs.

4. Revisión de nombres ambiguos en la fuente

Al construir listas de exclusión, verificar cada ítem contra los datos reales con `df['Item'].unique()`. Si un nombre parece un agregado pero aparece en los datos con valores plausibles, es un ítem hoja. La documentación de la fuente puede ser engañosa — los datos son la fuente de verdad.

Respuesta corta para el tribunal: El pipeline ejecutó sin errores pero `pct_Lacteos_Huevos` salió al 0.3% en vez del 10-15% esperado. La causa fue que `Eggs` y `Milk - Excluding Butter` se clasificaron erróneamente como ítems agregados y se filtraron antes del mapeo — el nombre FAO *"Milk - Excluding Butter"* induce a error. Se detectó por inspección estadística del output (mediana = 0 en toda la categoría es una señal de alarma inequívoca). La solución fue corregir `ITEMS_AGREGADOS`, eliminar un duplicado en el diccionario y re-ejecutar el notebook. La lección principal: validar rangos esperados del output como assertions al final del pipeline, y cruzar MAPEO_FAO contra ITEMS_AGREGADOS para detectar solapamientos.

CONCEPTO Y COMUNICACIÓN

Q13 ¿Qué entendemos exactamente por "dieta" en este TFM? ¿Cómo se lo explicamos al tutor?

Negocio · Metodología

En el lenguaje cotidiano, "dieta" suele evocar lo que una persona concreta come cada día, o un régimen de adelgazamiento. En este TFM usamos el término en un sentido distinto y más técnico, que conviene aclarar desde el primer momento con el tutor.

Lo que "dieta" significa en este proyecto: la distribución proporcional de las kilocalorías disponibles en el sistema alimentario de un país, agrupadas en 7 macrocategorías.

No es lo que la gente come individualmente — es la **huella estructural del sistema alimentario nacional** tal como la mide la FAO. Lo que el país "pone sobre la mesa" en términos de energía disponible por persona y día.

Ejemplo concreto — España 2018

La dieta de España en 2018 no es "Juan desayuna tostadas y María come ensalada".
La dieta de España en 2018 es:

```
%_Cereales: 25.3%  ·  %_Carnes: 18.9%  ·  %_Aceites_Grasas: 14.8%
%_Frutas_Verduras: 16.2%  ·  %_Lacteos_Huevos: 12.1%
%_Azucares: 9.4%  ·  %_Tuberculos: 3.3%
Total: 3.240 kcal/cápita/día
```

¿Por qué esta definición y no otra?

- **Es comparable entre países.** No importa que España coma 3.200 kcal/día e India 2.100 — los porcentajes ponen a ambos en la misma escala.
- **Es el dato que existe a nivel global.** El FBS de la FAO es el único dataset público con esta cobertura para 190+ países. No hay encuestas individuales comparables a escala mundial.
- **Permite clustering significativo.** Dos países con el mismo vector porcentual tienen la misma "identidad dietaria" aunque su ingesta total sea distinta. Esa similaridad estructural es lo que K-Means puede detectar.

Cómo comunicárselo a Pedro: una frase que funciona bien es — *"Nosotros no analizamos lo que come una persona, analizamos la huella calórica de lo que un país produce y distribuye para consumo humano, expresada como proporción entre grupos de alimentos. Es la fotografía estructural de la alimentación nacional, no el menú individual."*

> **Respuesta corta para el tribunal:** "Dieta" en este TFM es el vector de 7 proporciones (% de kcal por macrocategoría) que describe cómo un país distribuye su energía alimentaria disponible según la FAO. No es la ingesta individual ni un régimen — es la estructura calórica del sistema alimentario nacional, medida de forma comparable entre países y años.

Q15 ¿El DES refleja solo lo que produce el país o también lo que importa y exporta?

Metodología · Datos

El DES **no es producción bruta** — es el resultado de un balance completo que ya incorpora los flujos comerciales. La ecuación del FBS (Food Balance Sheet) de la FAO es:

Ecuación del balance alimentario FAO

```
Disponibilidad = Producción + Importaciones + Stock inicial
                 - Exportaciones - Stock final
                 - Pienso animal - Semilla - Uso industrial - Pérdidas

DES (kcal/cápita/día) = Disponibilidad para consumo humano / población / 365
```

Implicación directa para el TFM: cuando decimos "España tiene 3.240 kcal/cápita/día" no estamos diciendo que España produce todo eso. Estamos diciendo que España tiene eso *disponible para comer*, sea de producción propia o importado, una vez descontado lo que sale del país (exportaciones) y lo que no se destina a consumo humano (pienso, semilla, pérdidas en cadena, uso industrial).

Ejemplo ilustrativo: Arabia Saudí tiene una producción agrícola muy limitada pero un DES elevado gracias a su capacidad importadora. España exporta gran cantidad de aceite de oliva y frutas, por lo que su DES de esos grupos es menor que su producción real. El FBS captura ambas casuísticas correctamente.

> **Respuesta corta para el tribunal:** El DES ya integra comercio exterior. Es producción + importaciones − exportaciones − usos no alimentarios, dividido entre población y días. No mide lo que el país produce — mide lo que el país pone a disposición de su población para comer.

Q16 ¿Toda la comida disponible en el DES se consume? ¿Qué pasa con lo que no se come?

Metodología · Datos

No. El DES es **disponibilidad**, no ingesta real. Hay una brecha entre lo que el sistema alimentario pone disponible y lo que efectivamente entra en el cuerpo de las personas.

Qué descuenta el DES (pérdidas ya restadas):

- Pérdidas post-cosecha en campo y almacenamiento
- Mermas en transporte y distribución
- Deterioro en retail (productos que caducan antes de venderse)

Qué NO descuenta el DES (brecha residual):

- **Desperdicio en el hogar** — lo que el consumidor compra, no come y tira
- **Sobras en restauración** — comida preparada que no se sirve o no se termina

> **Magnitud de la brecha**
>
> En países desarrollados, la ingesta real es aproximadamente un **20–30% menor** que el DES. Es decir, de 3.240 kcal/día disponibles en España, una persona real ingiere del orden de 2.300–2.600 kcal. La diferencia es desperdicio doméstico y de restauración que la FAO no puede medir a escala global.

Implicación para el TFM y cómo comunicarlo: nuestro modelo trabaja sobre disponibilidad estructural, no sobre ingesta exacta. Asumimos que el *patrón proporcional* de disponibilidad (los porcentajes entre macrocategorías) es un proxy válido del patrón de consumo real, aunque el volumen absoluto esté sobreestimado. Esta limitación es inherente a cualquier análisis comparativo a escala global — no existe ningún dataset público con encuestas de ingesta individual comparables para 190+ países. El FBS es el único instrumento disponible.

> **Respuesta corta para el tribunal:** El DES mide disponibilidad, no ingesta. El desperdicio en el hogar y en restauración no está descontado, lo que hace que el DES sea un 20–30% superior a la ingesta real en países desarrollados. Trabajamos con disponibilidad como proxy del patrón de consumo porque no existe alternativa con cobertura global comparable. Es una limitación conocida, documentada y asumida explícitamente en la memoria.

EXTENSIONES Y PROPUESTAS DE NEGOCIO

Q17 ¿Podría el proyecto calcular el precio de un alimento en función de las condiciones de cada país? Negocio Metodología

Sí, y es una extensión natural del TFM que refuerza directamente el título del proyecto: *"¿Cuánto cuesta lo que comemos?"*. La pregunta de negocio detrás es: **el mismo alimento no cuesta lo mismo en todos los países** — ¿qué factores estructurales explican esa diferencia y podemos modelarlos?

Qué requeriría esta extensión:

- **Target nuevo (Y):** precio en USD/kg (o USD/1000 kcal) por macrocategoría y país — disponible parcialmente en FAOSTAT Prices y en datasets como World Bank Food Prices.
- **Predictores (X):** Food CPI del país, PIB/cápita, dependencia importadora de esa categoría (ratio importaciones/producción), distancia a centros de producción global, tipo de cambio, y el propio vector de disponibilidad DES.
- **Modelo:** LightGBM con SHAP — idéntica arquitectura al Motor B ya implementado. Reutilización directa del pipeline.

Valor de negocio concreto:

- **Para política pública:** identificar qué alimentos son precio-sensibles a factores importadores vs. productivos en cada país. Una subvención a cereales tiene efectos distintos en España (productor neto) que en Etiopía (dependiente de importaciones).
- **Para el simulador What-If:** añadir una tercera dimensión al gauge — además de CO2 y CPI, mostrar el precio estimado por kcal si un país adoptara un perfil dietario diferente. La frase de negocio: *"Si España adoptara el perfil dietario de Japón, la cesta de la compra costaría X% más/menos."*
- **Para industria alimentaria:** modelar cómo el precio de una categoría varía según el contexto país antes de entrar en un nuevo mercado.

Estado actual y viabilidad

Los datos de Food CPI ya están en el pipeline (columna `Food_CPI` en el parquet). Para una v2 del proyecto, añadir precios por categoría desde FAOSTAT Prices o World Bank implicaría un nuevo notebook de ingesta de datos y reentrenamiento del Motor B con el nuevo target. Complejidad: media. Impacto en la narrativa de defensa: alto — cierra el círculo del título con un output cuantificable por alimento y por país.

Propuesta para la defensa: mencionar esta extensión en la sección de "Trabajo futuro" — no como algo pendiente por falta de tiempo, sino como una línea de producto clara con viabilidad técnica demostrada. El tribunal de negocio valora que el equipo vea más allá del MVP entregado.

METODOLOGÍA DE COMPARACIÓN ENTRE DIETAS

Q18 ¿Cómo establecen que la dieta de un país es realmente distinta a la de otro? ¿Cuánto tiene que variar un porcentaje en una macrocategoría para que sea significativo?

Metodología

La pregunta es exactamente la correcta, y la trampa está en intentar responderla mirando una sola categoría. Si España tiene un 15% en Cereales y otro país tiene un 20%, esa diferencia de 5 puntos puede ser irrelevante o decisiva — depende del vector completo.

1. La unidad de comparación es el vector, no la categoría individual

Cada país-año es un punto en un espacio de 7 dimensiones (las 7 macrocategorías pct_) donde todas las coordenadas suman exactamente 1.0. Comparar dos dietas es calcular la distancia entre dos puntos en ese

espacio, no la diferencia en un eje aislado.

```
España 2018:  [Cer: 0.33 · Car: 0.16 · Lac: 0.19 · Ace: 0.14 · Azu: 0.09 · Fru: 0.06
· Tub: 0.03]
Etiopía 2018: [Cer: 0.62 · Car: 0.06 · Lac: 0.08 · Ace: 0.07 · Azu: 0.03 · Fru: 0.05
· Tub: 0.09]
```

2. Métrica operacional: distancia euclidiana en espacio porcentual

La fórmula es la misma que usa K-Means internamente para asignar cada país a su clúster:

$$d(A, B) = \sqrt{\left(\Sigma_i \, (pct_A_i - pct_B_i)^2 \right)} \quad \text{para } i = 1..7$$

Rangos orientativos (se calibrarán con los valores reales del nb03):

- **d < 0.10** → dietas muy similares — probablemente mismo clúster
- **0.10 ≤ d < 0.20** → diferencia moderada — tipología parecida, posiblemente mismo clúster
- **d ≥ 0.20** → diferencia estructural — típicamente clústeres distintos

3. Criterio individual por macrocategoría (diagnóstico complementario)

Una variación en una sola categoría solo es diagnóstica cuando se cumple alguna de estas condiciones:

- ≥ 8 pp en una categoría de **alto peso** (Cereales, Carnes, Lácteos_Huevos): son los ejes que más desplazan el vector
- ≥ 4 pp en una categoría de **bajo peso** (Tubérculos, Azúcares, Frutas_Verduras): una diferencia de 4pp ahí supone doblar o reducir a la mitad su presencia relativa
- Diferencia en **múltiples categorías simultáneamente**, aunque ninguna supere el umbral anterior — el efecto acumulado sí desplaza el vector

Restricción composicional clave: si Cereales sube 10pp, el resto del vector tiene que bajar 10pp en total. No se puede analizar una categoría sin considerar qué categorías compensan ese movimiento.

4. Criterio operacional definitivo: pertenencia al clúster

La respuesta más limpia para el tribunal: **dos países con asignación de clúster distinta tienen dietas estructuralmente distintas por definición del modelo**. K-Means minimiza la distancia intra-clúster y maximiza la inter-clúster — la frontera entre clústeres es la frontera entre tipologías dietarias.

La validación de que esa frontera es real (y no un artefacto del algoritmo) viene del **Silhouette Score ≥ 0.25** y del **Davies-Bouldin Index**. Si ambas métricas validan el K elegido, los clústeres son estadísticamente separables y las diferencias dietarias que los generan son objetivamente significativas.

> **Por qué no usamos un único umbral fijo de "X% de diferencia":** porque los datos son composicionales. Decir "5pp de diferencia en Cereales es significativo" ignora que esos 5pp tienen que venir de algún sitio. Dos países que difieren solo en Cereales pero son casi idénticos en las otras 6 categorías tendrán una distancia euclidiana baja (~0.07) y acabarán en el mismo clúster. Dos países que difieren en varias categorías a la vez, aunque ninguna supere el umbral individual, acumularán una distancia alta y tipologías distintas. El vector completo siempre prevalece sobre cualquier categoría aislada.

Respuesta corta para el tribunal: Medimos distancia euclidiana entre vectores dietarios de 7 dimensiones — la misma métrica que usa K-Means. Individualmente, diferencias ≥ 8pp en categorías dominantes o ≥ 4pp en categorías menores son diagnósticas. Pero el criterio definitivo es la pertenencia al clúster: si el modelo los separa y el Silhouette Score valida esa separación, las dietas son objetivamente distintas.

CLUSTERING — RESULTADOS Y VALIDACIÓN

Q19 ¿Qué tipologías dietarias encontró el modelo? ¿Tienen sentido los clústeres?

Metodología Datos

El modelo identificó **3 tipologías dietarias** (K=3) con una distribución geográfica coherente con la teoría nutricional y la geografía económica. Los clústeres no fueron predefinidos — emergieron de los datos.

Clúster 0 — Dieta Proteica Diversificada (229 obs · 18 países)

- Rasgo dominante: Lácteos_Huevos 20.0% · Aceites_Grasas 14.5% · Carnes 11.7% · Cereales 31.4%
- La más diversa entre categorías — ninguna macrocategoría domina de forma absoluta
- Países: Argentina, Australia, Brasil, Canadá, Colombia, Francia, Alemania, Italia, Kazajistán, México, Polonia, Corea del Sur, Rumanía, Arabia Saudí, España, UK, USA
- Patrón: países de renta media-alta con acceso estable a proteína animal y diversidad alimentaria

Clúster 2 — Dieta Cereal-Dependiente (148 obs · 12 países)

- Rasgo dominante: Cereales 59.6% — casi 60% de la energía proviene de cereales (arroz, trigo, maíz)
- Todo lo demás es bajo: Carnes 5.9% · Lácteos_Huevos 8.1% · Aceites 8.9%
- Países: Bangladesh, China, Egipto, Etiopía, India, Indonesia, Kenia, Marruecos, Senegal, Tailandia, Vietnam
- Patrón: países en desarrollo de Asia y África subsahariana donde el cereal es el pilar energético de subsistencia

Clúster 1 — Dieta Tuberosa Subsahariana (13 obs · 1 país: Nigeria)

- Rasgo dominante: Tubérculos 28.2% + Cereales 45.0% — combinación única en los 30 países analizados
- Proteína animal casi ausente: Carnes 2.5% · Lácteos_Huevos 1.8%
- Nigeria como clúster singleton es un hallazgo legítimo: su dependencia de ñame y yuca no tiene equivalente en la muestra

Coherencia con teoría: los clústeres reproducen exactamente las tres grandes familias dietarias descritas en la literatura de nutrición global — dieta occidental diversificada, dieta asiática cereal-dependiente, y dieta africana de tubérculos. El modelo no las conocía; las encontró.

Q20 ¿Por qué K=3 y no K=4, 5 o 6? ¿Cómo justifican esa elección?

Metodología

La selección de K se hizo con dos métricas complementarias, no con la curva de codo (que es orientativa, no concluyente):

K	Silhouette ↑	Davies-Bouldin ↓	Inertia	Veredicto
3 ✅	**0.3995**	**0.9083**	**1371.2**	**Óptimo en ambas métricas**
4	0.3482	1.1284	1122.7	Silhouette cae, DB sube
5	0.3419	1.1670	970.3	Mínimo Silhouette del barrido
6	0.3587	1.1240	848.9	Recupera algo de Silhouette pero DB sigue alto

Interpretación: K=3 maximiza el Silhouette (0.3995 — 14.7% mejor que el siguiente) y minimiza el Davies-Bouldin (0.9083 — el único K con DB por debajo de 1.0). Todos los K superan el umbral mínimo de Silhouette ≥ 0.25, pero K=3 domina en ambas dimensiones simultáneamente.

El descenso de Silhouette a partir de K=4 indica que subdividir los clústeres existentes **crea grupos menos cohesionados y menos separados** — el algoritmo empieza a fragmentar estructuras reales en lugar de descubrir estructuras nuevas.

> **Respuesta corta para el tribunal:** K=3 es el único K que maximiza Silhouette y minimiza Davies-Bouldin simultáneamente. Cualquier K mayor fragmenta estructuras reales en lugar de descubrir tipologías nuevas. Además, los tres clústeres tienen interpretación narrativa directa y coherente con la literatura dietaria global.

Q21 ¿Por qué Nigeria forma su propio clúster? ¿No es un problema que sea un singleton?

Datos · Metodología

Nigeria como clúster singleton no es un artefacto — es el hallazgo más interesante del clustering. Su perfil dietario es estructuralmente distinto al de cualquier otro país de los 30 analizados.

Por qué Nigeria es única:

- **Tubérculos 28.2%** — ningún otro país de la muestra supera el 10% en Tubérculos. Nigeria tiene la tradición culinaria del ñame (yam) más alta del mundo: produce más del 60% del ñame mundial
- **Cereales 45.0% + Tubérculos 28.2% = 73.2%** de la energía en solo dos categorías. Una concentración sin paralelo en la muestra
- **Proteína animal casi ausente**: Carnes 2.5% · Lácteos_Huevos 1.8%. Combinado con el alto volumen de tubérculos, define un patrón dietario de subsistencia agrícola específico del oeste de África

¿Es un problema metodológico? No. Un singleton en K-Means ocurre cuando un punto está tan alejado del centroide de cualquier otro clúster que el algoritmo lo asigna solo. Aquí no es outlier ruidoso — es un perfil real y estable: Nigeria mantiene este patrón los 13 años del dataset (100% estabilidad temporal).

Qué dice sobre la muestra: los 30 países fueron elegidos por máxima varianza geográfica, económica y climática. Nigeria representa el patrón dietario de África Occidental, y ese patrón es lo suficientemente distinto para no colapsar con ningún otro clúster sin perder información real.

Respuesta corta para el tribunal: Nigeria no es un outlier ruidoso — es un perfil dietario estructuralmente único: Tubérculos 28% (ñame/yuca), el más alto de los 30 países. El singleton es un resultado, no un problema. Si lo forzáramos a entrar en K=2, perderíamos exactamente la información más valiosa que el modelo puede revelar.

Q22 ¿Algún país cambió de tipología dietaria a lo largo de los años? ¿Qué significa eso?

Datos · Metodología

Sí, uno: **Pakistan**. El 98.7% de las observaciones son estables (29 de 30 países mantienen el mismo clúster durante los 13 años). Pakistan es el único caso de transición documentada.

El patrón de Pakistan (2010–2022):

- 2010–2011: Clúster 2 (Cereal-Dependiente) — Cereales ~60%, proteína animal baja
- 2012–2015: oscilación entre ambos clústeres
- 2016–2022: Clúster 0 (Proteica Diversificada) — aumento progresivo de Carnes y Lácteos, descenso relativo de Cereales

Interpretación: Pakistan vivió entre 2013 y 2018 un período de crecimiento del PIB per cápita sostenido (~4-5% anual). El patrón observado — reducción relativa de cereales, aumento de proteína animal — es exactamente el *nutrition transition* documentado en la literatura: cuando los ingresos suben, las dietas se diversifican hacia proteína animal y procesados.

Valor para el TFM: este hallazgo refuerza que los clústeres capturan algo real — no son agrupaciones arbitrarias sino tipologías que responden a la economía de cada país. Pakistan no cambia de clúster por ruido estadístico; cambia porque su estructura dietaria cambió de forma medible.

Respuesta corta para el tribunal: Pakistan es el único país en transición — migra de Cereal-Dependiente a Proteica Diversificada entre 2013 y 2016, correlacionado con su período de crecimiento económico. Es evidencia directa de que los clústeres capturan transiciones dietarias reales, no artefactos del algoritmo.

MOTOR B — LIGHTGBM + SHAP

Q23 ¿Cuál fue el resultado del Motor B? ¿Qué R^2 obtuvo el modelo?

Metodología · Resultados

El Motor B superó ampliamente el objetivo marcado. Resumen de métricas (validación cruzada 5-fold):

Modelo	Target	R^2 CV	MAE	Objetivo ≥0.40
Baseline — Regresión Lineal	CO_2eq t/cápita	0.2915	1.25 t	✗
LightGBM	**CO_2eq t/cápita**	**0.8641**	**0.41 t**	✅

Modelo	Target	R^2 CV	MAE	Objetivo ≥0.40
LightGBM (intensidad)	CO_2eq/Kcal	0.8397	0.36	✅

Interpretación: el modelo explica el 86.4% de la varianza en emisiones CO_2 per cápita a partir exclusivamente de la composición dietaria + el índice de precios (Food CPI). La Regresión Lineal (baseline) solo llega al 29.2% — LightGBM gana +57 puntos de R^2 gracias a su capacidad de capturar relaciones no lineales y umbrales de saturación.

Robustez del resultado: la desviación estándar del R^2 en los 5 folds es ±0.050 — consistente entre pliegues, sin colapso en ningún fold. El overfitting gap (R^2 train=0.996 − R^2 test=0.864 = 0.132) está dentro del límite aceptable para el tamaño del dataset (n=390).

Output generado: `processed/04_model_results.parquet` — 390 filas × 28 columnas, incluyendo predicciones CV, residuos y 9 columnas SHAP individuales por observación.

> **Respuesta corta para el tribunal:** LightGBM alcanza R^2=0.864 en validación cruzada, superando en más del doble el objetivo mínimo de 0.40 y multiplicando por 3 la capacidad explicativa de la regresión lineal. El modelo captura la señal climática del sistema agroalimentario exclusivamente desde comportamiento dietario y precios.

Q24 ¿Qué variables explican más las emisiones CO_2 según SHAP? ¿Son coherentes con la teoría?

Metodología Resultados

SHAP (SHapley Additive exPlanations) asigna a cada observación la contribución individual de cada feature a la predicción. Ranking de importancia global (|SHAP| medio sobre las 390 observaciones):

Rank	Feature	|SHAP| medio	Lectura narrativa
#1	`pct_Cereales`	**0.5572**	Principal discriminador: alta proporción de cereales caracteriza a dietas de bajo impacto (C2 subsistencia) o contrasta con dietas ricas en proteína (C0).
#2	`pct_Azucares`	**0.5145**	Alto contenido en azúcares aparece asociado con dietas procesadas y mayor huella de CO_2 del sistema alimentario.
#3	`pct_Carnes`	**0.5027**	Carne es el tercer driver — coherente con IPCC: la ganadería intensiva tiene alta huella de CO_2eq por Kcal producida.
#4	`pct_Tuberculos`	0.2164	Importante por el efecto Nigeria (C1, singleton): alta proporción de tubérculos es un marcador de la tipología Subsahariana.
#5–7	`pct_Aceites_Grasas`, `pct_Lacteos_Huevos`, `pct_Frutas_Verduras`	0.16 – 0.11	Importancia moderada. Aceites y Lácteos señalan dietas diversificadas de renta alta.
#8	`log_Food_CPI`	0.0729	Baja importancia — la composición dietaria es mucho más informativa del CO_2 que el nivel de precios.

Rank	Feature	|SHAP| medio	Lectura narrativa
#9	`cluster_id`	0.0441	Mínima importancia marginal: el vector dietario puro ya contiene casi toda la señal; el clúster añade contexto residual.

Nota sobre los signos SHAP en datos composicionales: en datos donde las features suman 1.0, el efecto de una feature sobre el target es inherentemente dependiente del contexto. El *SHAP medio con signo* tiende a ser próximo a cero porque los efectos positivos y negativos se compensan entre distintos rangos de valor. El canal correcto para analizar la dirección es el *beeswarm plot* (generado en `processed/04_shap_global.png`), que muestra la distribución observación a observación.

Coherencia con teoría IPCC (Poore & Nemecek, 2018): los tres primeros drivers son exactamente las variables que la literatura señala como principales diferenciadores de huella ambiental entre tipologías dietarias. La carne ocupa el puesto esperado. El resultado de SHAP no reproduce un ranking ad hoc — reproduce la jerarquía de impacto documentada en revisiones sistemáticas.

> **Respuesta corta para el tribunal:** Los tres principales drivers SHAP son pct_Cereales (0.557), pct_Azúcares (0.515) y pct_Carnes (0.503) — con importancia prácticamente igual entre ellos. El Food CPI aporta solo 0.073: la estructura de lo que se come predice el CO_2 mucho mejor que el precio de los alimentos. Los resultados son coherentes con la jerarquía de impacto del IPCC.